

局部模态缺失下的 多模态情感预测

论文重组稿 | 以已实现方法与实测结果为主线

稿件使用说明

本稿根据已完成的研究重组章节，原目录仅作为选材参考。第 4 章集中说明模型，第 5 章集中呈现实验与专项预测。

正文以第二问实测工作为主体。第一问与第三问保留任务背景及衔接说明；未执行的第一问方案和 100 条原始清单另存写作素材。

观测状态递推保留为自建候选；最终专项预测使用按预定规则选中的 EMT-DLFR 适配版，避免模型叙述与结果来源不一致。

本文为阶段性论文工作稿，并非整题完稿。后续应按第一问、第三问的实际成果调整整体章序，最终统一竞赛模板与参考文献格式。

目录

- 1 问题重述与分析
 - 1.1 问题背景
 - 1.2 问题重述
 - 1.3 问题分析
 - 1.4 研究现状与方法选择依据
 - 1.5 总体建模思路与技术路线
- 2 模型假设与符号说明
 - 2.1 模型基本假设
 - 2.2 主要符号与变量定义
- 3 数据审查与预处理
 - 3.1 数据集构成与各附件使用范围
 - 3.2 样本编号对应与数据完整性检查
 - 3.3 标签定义与训练、验证数据组织
 - 3.4 序列有效长度、填充位置与模态缺失的区分
 - 3.5 异常值处理与特征标准化
 - 3.6 样本分布与数据质量统计
- 4 局部模态缺失下的情感预测模型
 - 4.1 局部连续缺失的数学描述
 - 4.2 基于观测状态感知递推的鲁棒融合模型
 - 4.3 跨模态交互与特征恢复对照模型
 - 4.4 联合预测目标与两级恢复约束
 - 4.5 连续区间缺失增强
- 5 实验验证、模型选择与专项预测
 - 5.1 训练配置与模型选择规则
 - 5.2 评价指标与结果统计
 - 5.3 验证集基础性能与基线对比
 - 5.4 模态缺失对预测性能的影响规律
 - 5.5 核心模块消融实验
 - 5.6 预测结果可视化与错误归因
 - 5.7 附件 3 全量预测结果汇总与结果文件说明
 - 5.8 适用范围与后续任务衔接
- 参考文献

1 问题重述与分析

1.1 问题背景

情感预测是自然人机交互、智能客服和具身智能中的基础任务。人在表达态度时，词语内容、语音韵律和面部行为通常同时参与：文本提供语义线索，音频反映语速、停顿和声音变化，视觉提供表情与动作信息。单一模态可能出现语义歧义或观测不足，因而需要建立能够利用多源信息的预测模型。

实际场景与理想的完整输入存在差异。音视频采样频率不同，词语持续时间不等，特征序列需要明确的对应关系；转写失败、声学干扰和人脸检测失败可能造成局部观测不可用；预测模型即使输出准确，也可能无法说明其主要依据。因此，本题需要同时处理特征提取与对齐、局部缺失下的稳定预测，以及可回查原始素材的解释三个问题。

本研究以赛题提供的 CMU-MOSEI 相关视频与标准化特征为唯一情感建模数据来源[1]。对于情感极性采用负向、中性、正向三分类，对于强度采用连续值回归。通用预训练编码器用于基础特征处理，模型参数、结构选择与结果统计均服从题目规定的数据使用边界。

1.2 问题重述

1.2.1 问题一：多模态特征提取与时序对齐

针对附件 1 的 100 条原始视频及配套英文转写文本，建立文本、语音、视觉三种情感相关特征的定义、提取和对齐流程。输出须覆盖全部样本，保留样本标识、特征矩阵、有效长度、填充规则与原素材的对应记录；说明工具版本和关键参数，并通过典型样本展示文本片段、语音区间、视频帧段之间的对应关系。自主生成的特征文件应具有完整性、可核验性和可复现性。

1.2.2 问题二：局部模态缺失下的鲁棒情感预测

针对一个或多个模态的部分连续位置不可用的情形，利用附件 2 训练集建立情感极性与强度预测模型，在验证集选择结构及参数，并分析缺失模态类型、缺失位置和区间长度对性能的影响。局部缺失不等于整路模态完全不存在。最终使用冻结的预测器对附件 3 全部 30 条无标签样本输出结果。第一问自提特征不是第二问训练的必需前置输入。

1.2.3 问题三：可解释性情感预测

针对决策依据不易追溯的问题，建立同时输出情感预测、主要参考模态、模态作用程度与局部关键证据的分析方法。模型仍在附件 2 训练/验证划分上学习与选择，附件 4 的 20 条样本用于最终

预测和解释。关键证据需要对应原始文本片段、语音时段或视觉关键帧，不能只给出没有原素材对应关系的注意力热力图。

1.3 问题分析

1.3.1 多模态时间尺度差异与特征对应问题

文本以词或子词组织，声学特征通常以短时窗采样，视觉以视频帧组织，三者长度与时间分辨率不同。仅将三个矩阵截成同样行数，不能保证相同行具有相同时间含义。问题一应建立统一时间基准，并保存词到子词、子词到时间区间和音视频聚合窗口的映射。对于官方对齐特征，只接受题目给定的序列对应形式，不自行把第 j 行解释为视频的第 $j/50$ 时刻。

附件 1 与附件 2 不是同一批样本。先前审计发现 100 条原始样本只有 18 条 ID 在附件 2 中出现，故不能用附件 2 特征代替问题一的自主提取。问题一的工具、特征维数可以合理选择，但即使与附件 2 维数相同，也不能据此认定两者语义或提取流程一致。

1.3.2 连续局部缺失与情感预测稳定性问题

连续缺失会在相邻位置同时移除情感线索，影响跨模态补充与时序记忆。建模时需要区分内容范围、原始可用性和人工遮挡三个概念，保留中间空位的顺序，使缺失长度提示和状态传播有明确含义。音视频全零行只能被操作性地识别为不可用观测，其成因无法仅凭数值判定。

本题属于不完整观测下的监督多模态序列到样本学习，而非预测未来时刻的时间序列外推。本文先构建可用观测融合及隐状态递推候选，再使用 MLP、GRU 和公开论文结构进行验证。模型复杂度的增加是否有效由统一条件下的实测决定，不预先假定状态递推或特征恢复一定更优。

1.3.3 模态作用量化与原始证据追溯问题

模型解释包含模态层面和局部位置层面。可通过控制输入扰动，测量某种模态或某段内容被移除后的类别概率与强度变化，再对关键区域回看原素材。由于不同模态可能包含冗余信息，单次删除后预测不变并不必然说明该模态未起作用；归因需要考虑模态组合并进行忠实性检验。

问题二的遮挡工具可以复用于问题三，但评价目的不同：问题二比较预测与真实标签，问题三比较模型判断在受控扰动前后的变化。附件 4 对齐版 13 号视觉全零，应标记为视觉不可用，而非解释为视觉贡献低。恢复器生成的表示属于模型估计，也不能充当视频中真实出现的表情证据。

1.4 研究现状与方法选择依据

多模态情感分析的相关研究主要从跨模态交互与不完整观测恢复两个方向展开。低秩多模态融合 LMF 通过因子分解表达模态间乘性交互[2]；MulT 利用多个方向的跨模态注意力，将源模态信息

传递到目标序列[3]；TFR-Net 引入特征重建以处理不完整多模态输入[4]；EMT-DLFR 通过全局—局部交互结合低层重建与高层表示吸引，提高缺失条件下的表示稳定性[5]。

这些方法与赛题的输入和评价口径存在差异。部分开源实现使用逐位置随机缺失、二分类评价或不同的文本编码器，不能直接套用论文中的数值。本文实际完成 MulT 和 EMT-DLFR 的赛题适配，统一为三分类与回归、同一冻结文本编码器和连续区间评价；LMF 与 TFR-Net 仅作为相关工作介绍，不报告未运行方法的实验成绩。

1.5 总体建模思路与技术路线

总体流程为“附件审查—统一表示与掩码—候选模型训练—缺失条件验证—专项推理与证据追溯”。数据审查先确定样本身份与输入接口，问题一以原始视频为入口建立自主特征和时间映射；问题二直接使用附件 2 的对齐版本，统一重编码文本，比较融合与递推模型并开展缺失消融；问题三可以复用合格预测器与掩码接口，但需另行完成模态作用分析和原视频定位。

当前第二问的正式实验和附件 3 预测已完成。第一问完成了原始视频清单核查，但尚未生成自主三模态特征；第三问尚未完成专项加载、解释验证和真实时间映射。因此，正文重点展开已实现的缺失预测模型与实验，第一问的待实施方案另存写作素材；第三问的证据映射与解释评估须待实际完成后纳入。




图 1 总体技术路线及当前完成范围

2 模型假设与符号说明

2.1 模型基本假设

假设 1：赛题给定的样本身份和情感标注作为监督依据予以保留，不根据模型输出擅自修改标签。该假设不要求每条标注完全无噪声；预测误差分析仍需考虑语义歧义与标注不确定性。

假设 2：在所选择的官方对齐版本中，不同模态的同一存储位置具有题目规定的对应关系。该关系仅用于位置级建模，不进一步假设各位置等时长或已经具有已知的真实时间戳。

假设 3：内容位置由特殊词元与注意力信息共同识别。对本批官方附件，在内容范围内音视频的有限非零行视为可用观测；token 100 按已核验的专项缺失约定处理。全零特征的真实来源不作额外推断，通用文本中的未知词也不一律等价于缺失。

假设 4：训练集上计算的可用观测均值和标准差能够作为验证及专项输入的共同尺度。训练、验证划分保持官方的原视频分组隔离，不假定不同视频分布完全一致。分布偏移对专项泛化的影响作为结果局限保留。

假设 5：人工连续遮挡可以用于研究局部观测损失对预测的影响，但它不被假定为附件 3 真实生成机制的精确复现。缺失增强只移除原有信息，不利用专项文本匹配或跨版本补回原始内容。

假设 6：状态递推中的隐变量是为片段级预测学习的潜在表示，而不是经测量验证的瞬时情绪状态。其传播与更新结构借鉴部分观测系统的思想，不赋予严格卡尔曼滤波、已知动力学或最优控制的结论。

假设 7（仅用于第一问拟定方案）：英文转写与音频具有足够的内容对应性，能够进行词级强制对齐；对齐置信度低、原文不匹配或无法定位的片段须保留失败标记。此假设尚需在 100 条样本实际提取时验证，不能据此直接填入对齐误差。

2.2 主要符号与变量定义

表 1 主要符号与变量

符号	含义	取值或单位
i, m, t	样本、模态、存储位置索引	$m \in \{T, A, V\}$ ；官方 $t=0, \dots, 49$
X_i^m, x_{it}^m	模态特征矩阵及单位位置向量	第二问维数 256/74/35
s_{it}, L_i	内容位置掩码及内容长度	$s \in \{0, 1\}$ ； $L = \sum_t s_{it}$
o_{it}^m	人工遮挡前的可用观测掩码	1 为可用，不等同 attention
$b_{it}^m, \tilde{o}_{it}^m$	人工遮挡掩码、遮挡后的可用掩码	$\tilde{o} = s \cdot o \cdot (1 - b)$
ρ, r_i^m	目标遮挡比例、实际不可用比例	分母需注明内容或原可用位置

符号	含义	取值或单位
I_i, J_{ik}	连续位置区间、原素材时间区间	I 用索引; J 用秒, 二者不同
d_{it}^m, g_{it}^m	连续无观测步数及 log 间隔表示	$g = \log(1+d)$
h_{it}^m, u_{it}	模态投影表示与当前融合表示	自建模型维数 32
z_{it}, a, k_{it}	递推隐状态、保持系数、更新门	a 与 k 逐分量位于(0,1)
c_i, y_i	真实极性类别与连续强度	$c \in \{0,1,2\}; y \in [-3,3]$
$\hat{p}_i, \hat{y}_i$	预测类别概率、预测强度	$\sum c \hat{p}_i c = 1; \hat{y} \in [-3,3]$
μ^m, σ^m	训练可用观测的均值和标准差	逐特征维计算
G, H^m	EMT 全局上下文与局部表示	G 为 3 个 128 维 token
N, K	评价样本数、类别数	验证 $N=728$; $K=3$
$sg(\cdot), \odot$	停止梯度、逐元素乘法	训练运算符

3 数据审查与预处理

3.1 数据集构成与各附件使用范围

表 2 附件构成及使用边界

附件	规模与内容	本研究用途
附件 1	100 条视频，37 个原视频目录，英文文本与标签	问题一自主特征；本稿仅完成原始清单核查
附件 2	4850 条；训练 3395/验证 728/测试 727	训练拟合与开发验证；test 标签未用于选模
附件 3	30 条无标签局部缺失特征；两版本	第二问冻结模型后的最终推理
附件 4	20 条无标签视频及特征；两版本	第三问最终预测与证据回看，尚待实现

第二问选择 aligned_50 版本。官方文本连续特征维数为 768，音频 74，视觉 35；但附件 3 对齐版没有预计算 text 字段，因此训练、验证和专项统一从 text_bert 经固定 BERT-Mini 编码[6]，得到 256 维文本向量。这是共同输入接口的工程选择，不意味着新 256 维向量等价于官方 768 维特征。

3.2 样本编号对应与数据完整性检查

附件 1 以 video_id 和 clip_id 共同确定样本，原视频路径按两级目录对应。对 100 条清单逐一核对视频存在性并读取音视频轨道元数据，均能找到配套文件。此次仅核查容器及轨道可解析性，不将其等同于逐帧观看、语义校验或已完成特征提取。

附件 2 按划分与字段集中存储，样本应从 data[split][field][i] 读取。ID 使用 “video_id\$_clip_id” 格式，不能按下划线任意拆分。附件 3 缺少内部 id，采用原始文件名作为稳定标识并自然排序；附件 4 单条矩阵没有同样的批次轴，需要额外适配，不能直接复用附件 3 入口。

输入审计确认附件 3 有 4 条未对齐文本与附件 2 test 相同，附件 4 有 5 条四项特征与附件 2 test 完全相同。因此，附件 2 test 和专项测试不能无条件作为相互独立的两份证据。重合仅用于数据质量说明，未导出匹配标签，也未用于恢复专项缺失内容。

3.3 标签定义与训练、验证数据组织

$$c_i=0 \left(y_i<0 \right) ; c_i=1 \left(y_i=0 \right) ; c_i=2 \left(y_i>0 \right) \quad (3-1)$$

式（3-1）中分类编码 0 代表负向，而连续强度 0 代表中性，两者不可混淆。训练时分类标签转换为整数 long，回归标签转换为浮点数。附件 1 表格中的连续标签实际存为字符串，原始清单读取时显式转换为数值。

保留官方划分。训练集与验证集分别含 3395 和 728 条样本，原始 video_id 在训练、验证、测试划分之间无交集。标准化、类别先验、强度中位数等参数仅由训练集计算；验证集用于早停及结构选择，因此本文所有验证分数均是开发评价，不声称独立测试泛化精度。

3.4 序列有效长度、填充位置与模态缺失的区分

存储长度 50 包括[CLS]、内容词元、[SEP]和 padding，真实内容最多 48 个词元。本文用经核验的[SEP]定位内容尾端，排除特殊标记和 padding，同时保留内容区的内部空位。文本 attention 连续为 1 只说明位置存在，不能证明文字内容完整。

$$L_i = \sum_t S_{it} ; o_{it}^m \in \{0,1\} ; \tilde{o}_{it}^m = S_{it} o_{it}^m (1 - b_{it}^m) \quad (3-2)$$

附件 3 中 27/30 条含 token 100，即[UNK]，合计 131 处；内容区该掩码与音频全零位置在 30 条样本中逐位一致。配对输入还确认了原词元被替换而 attention 保持 1。故对本附件将 100 视为不可用文本标记，在 BERT 编码之前擦除词元、attention 及 segment，再按可用掩码清零输出。通用文本未知词的语义不作同样推断。

附件 2 对齐版音视频第 0 行与第 49 行均为结构性零；预计算文本在 padding 处仍有非零向量，不能以向量非零判断有效文本。未对齐版有 890 条样本在 vision_lengths 之后仍有非零视觉行，直接前缀裁剪会丢失观测；本研究选择对齐版避开该长度字段，并仍采用逐位置掩码，不将非零行压紧。




图 2 附件 3 中 attention 与内容可用性不同：03 号与 20 号实测掩码

3.5 异常值处理与特征标准化

首先校验字段、形状、词元整数性和有限性。附件 3 的 token 存为 float32，只有全部为合法整数且位于词表范围内时才转换为 long。第二问当前训练与验证音视频数据中未发现非有限元素；若未来遇到非有限行，按不可用观测处理并输出质量标记，而不静默删除样本。

$$\mu_j^m = (\sum_{i,t} o_{it}^m x_{itj}^m) / (\sum_{i,t} o_{it}^m), \quad i \text{ 仅取训练集} \quad (3-3)$$

$$\sigma_j^m = \max \{ \sqrt{[(\sum_{i,t} o_{it}^m (x_{itj}^m - \mu_j^m)^2) / (\sum_{i,t} o_{it}^m)]}, 10^{-5} \} \quad (3-4)$$

$$\tilde{x}_{itj}^m = (x_{itj}^m - \mu_j^m) / \sigma_j^m \quad (\text{观测可用}) ; \text{ 否则 } \tilde{x}_{itj}^m = 0 \quad (3-5)$$

式 (3-3) — (3-5) 用于音频与视觉，掩码在原始特征上先生成，再进行标准化；文本词元编号不做 Z-score。复查时仅用训练可用观测重算音视频均值和标准差，与已有统计量逐元素相同，最大绝对差为 0。原始 PKL 保持不变，异常处理只作用于模型输入。

3.6 样本分布与数据质量统计

表 3 数据分布与质量统计

项目	训练集	验证集	测试集/专项
样本数	3395	728	附件 2 test: 727
负向/中性/正向	967/758/1670	206/184/338	test 标签不作本轮统计
内容长度：最小/中位数/最大	1/20/48	1/21.5/48	单位：词元位置
内容位置总数	76882	17172	test: 16855
内容内音频不可用行	65	46	原因未知
内容内视觉不可用行	4249	980	原因未知
整条视觉全零样本	110	15	test: 28
未对齐视觉声明长度后仍非零	618	141	test: 131
文本 UNK 位置	0	0	test: 0; 附件 3: 131
专项输入异常	—	—	附件 4 对齐 13 号视觉全零

训练集正向占比为 49.19%，中性占 22.33%，负向占 28.48%；仅报告准确率会掩盖少数类别的识别差异，因此同时报告 Macro-F1 和逐类召回。训练与验证的视觉不可用行比例分别约为 5.53% 与 5.71%，这些比例以内容位置为分母，不包含 padding 和特殊 token。




图3 训练集与验证集的三类样本分布

附件3的01、05、10号内容区未发现文本UNK或音视频全零行；20号音频不可用14/48，约29.17%，30号为12/24，即50%。这些是特征位置的不可用比例，不能写成真实缺失时长比例，更不能使用“零行数÷50”得到所谓平均缺失率。

4 局部模态缺失下的情感预测模型

局部缺失同时改变可用观测和跨模态交互条件。本章在统一输入与掩码规则下，构建观测状态递推候选，并引入 MulT 和 EMT-DLFR 适配结构进行对照。前者检验缺失间隔与历史记忆的作用，后两者检验跨模态注意力及恢复监督的作用。模型是否保留用于专项推理由第 5 章的预定验证规则决定，而非由结构复杂度或先验直觉决定。

4.1 局部连续缺失的数学描述

4.1.1 缺失模态、缺失区间与观测掩码定义

对样本 i 的真实内容位置集合 $S_i = \{t: s_{it}=1\}$ ，选择模态子集 M_i 和连续区间 $I_i = [a_i, a_i + w_i)$ 。区间按内容位置生成，但保留原存储索引。人工遮挡仅改变可用掩码及对应输入，不删去序列行；双模态可共享同一区间，也可采用不同起点形成错位遮挡。

$$b_{it}^m = 1 (m \in M_i \text{ 且 } t \in I_i) ; \tilde{o}_{it}^m = s_{it} o_{it}^m (1 - b_{it}^m) \quad (4-1)$$

文本缺失在编码之前实施，防止被遮词通过上下文化编码泄漏到其他位置。音视频在投影前再次按 δ 屏蔽。原来不可用的位置与人工新遮挡分开记录，恢复监督只使用 $o=1$ 且 $\delta=0$ 的位置。

4.1.2 缺失位置、缺失时长与缺失率的计算

$$w_i = \min \{L_i, \max [1, \text{round}(\rho L_i)]\}, \rho > 0 ; \rho = 0 \text{ 时 } w_i = 0 \quad (4-2)$$

$$r_i^m = \sum_t s_{it} (1 - \tilde{o}_{it}^m) / L_i ; r_{new_i^m} = \sum_t o_{it}^m b_{it}^m / \sum_t o_{it}^m \quad (4-3)$$

r 表示内容中的总不可用比例， r_{new} 表示原可用观测中新增移除的比例；后者分母为 0 时记为不可计算，不报告成 0% 缺失。目标比例 ρ 控制区间位置预算，因取整及原始不可用位置存在，实际新移除观测比例可能与 ρ 不同。

缺失起点分别设置为前部、中部和后部，另设随机起点用于训练。当前没有原视频逐词时间映射，因此“时长”仅以连续位置数及内容比例代理，不能把 50% 词元解释为视频一半秒数。论文中所有缺失曲线均采用此口径。

4.2 基于观测状态感知递推的鲁棒融合模型

4.2.1 三模态特征编码与维度投影

$$h_{it}^m = \tilde{o}_{it}^m \cdot \tanh \{ \ln [W^m (\tilde{o}_{it}^m \tilde{x}_{it}^m) + b^m] \} \quad (4-4)$$

文本、音频、视觉分别由 256、74、35 维投影到 32 维。输入在学习变换之前屏蔽，投影后再乘可用掩码，防止偏置和归一化使不可用位置产生伪观测。文本编码器固定权重并使用 eval 模式，不参与情感标签微调。

4.2.2 观测状态与连续缺失间隔表示

对每种模态维护距最近可用观测的内容步数 d 。观测存在时归零，内容位置缺失时加一，padding 不推进计数。初始无观测区间从首个内容位置累计，间隔以 $\log(1+d)$ 压缩，与三种模态的可用状态拼接为 6 维描述。

$$d_t^m = 0 \quad (\tilde{o}_t^m = 1) \quad ; \quad d_t^m = d_{t-1}^m + 1 \quad (s_t = 1 \text{ 且 } \tilde{o}_t^m = 0) \quad (4-5)$$

$$g_t^m = \log(1 + d_t^m) \quad ; \quad q_t = [\tilde{o}_t^T, \tilde{o}_t^A, \tilde{o}_t^V, g_t^T, g_t^A, g_t^V] \quad (4-6)$$

4.2.3 当前可用模态的融合机制

$$e_t^m = w_2^T \tanh(W_1[h_t^m; q_t] + b_1) + b_2 \quad (4-7)$$

$$\alpha_t^m = \tilde{o}_t^m \exp(e_t^m) / \sum_n \tilde{o}_t^n \exp(e_t^n) \quad (4-8)$$

$$u_t = \tanh\{W_u[\alpha_t^T h_t^T; \alpha_t^A h_t^A; \alpha_t^V h_t^V; \tilde{o}_t] + b_u\} \quad (4-9)$$

式 (4-8) 只在当前可用模态间归一化；分母为 0 时令所有权重及 u_t 为 0。加权后按模态身份拼接，避免先求和丢失模态来源。这些权重用于预测融合，尚未经过第三问的解释忠实性验证，不直接称为真实因果贡献。

4.2.4 历史状态传播与观测更新机制

$$a = \text{sigmoid}(\theta) \quad ; \quad z_t^- = a \odot z_{t-1} \quad (4-10)$$

$$k_t = \text{sigmoid}\{W_k[z_t^-; u_t; q_t] + b_k\} \cdot 1(\exists m: \tilde{o}_t^m = 1) \quad (4-11)$$

$$z_t = (1 - k_t) \odot z_t^- + k_t \odot u_t, \quad \text{当 } s_t = 1 \quad (4-12)$$

初始化 $z_0 = 0$ ，保持系数初值为 0.98。内容位置全部模态不可用时，更新门为 0，仅传播历史；padding 直接保持上一步状态，不衰减也不参与池化。最终对真实内容位置的隐状态均值池化为片段表示。该结构表达了“无观测时保留历史、有观测时调整状态”的建模思想，但效果必须通过消融验证。

4.2.5 情感极性分类与情感强度回归

$$\bar{z}_i = (\sum_t s_{it} z_{it}) / \max(L_i, 1) \quad ; \quad \hat{p}_i = \text{softmax}(W_c \bar{z}_i + b_c) \quad (4-13)$$

$$\hat{y}_i = 3 \tanh[(W_r \bar{z}_i + b_r) / 3] \quad ; \quad \hat{c}_i = \arg\max_c \hat{p}_i c \quad (4-14)$$

极性和强度由独立输出头预测，强度限制在 $[-3,3]$ 。完全没有可用观测的样本使用训练类别先验及训练强度中位数，避免数值异常。独立输出头可能在接近 0 的区域出现类别与强度符号不一致，本文保留原始输出并统计该现象，不根据无标签专项结果临时修改阈值。

4.3 跨模态交互与特征恢复对照模型

4.3.1 普通基线与比较边界

普通对照包括：仅文本预测；各模态可用位置池化后拼接的 MLP；使用相同逐位置融合输入的 GRU；固定历史保持系数的平滑模型；以及自建状态递推及其变体。论文对照使用 MulT 和 EMT-DLFR。所有正式比较共享附件 2 划分、256/74/35 维输入、缺失规则和评价条件，但网络容量、优化目标和计算成本不同，不声称等参数量或等 FLOPs。

4.3.2 MulT 的成对跨模态注意力

MulT 保留六个方向的成对跨模态注意力，再将每个目标模态的两路表示拼接并经自注意力记忆网络汇总。适配时以最后真实内容位置代替固定末行，不可用源位置不作为注意力键，真实缺失目标位置仍可作为查询；最后输出三分类和有界回归。

4.3.3 EMT-DLFR 的全局—局部交互

EMT 先由音频/视觉 LSTM 获得 16/32 维局部及片段表示，文本使用共同编码的可用内容池化，投影到 128 维。三路片段表示构成全局上下文 G ，与各模态局部表示 H^m 双向交互，并聚合三路更新后的全局信息。方向、模态与层之间共享 MPU 参数，采用 4 头、2 层设置。局部缺失位置保留为可推断的潜在表示，但不可用原始值已清除；该表示不被当作原素材证据。

$$H^m \leftarrow MPU(H^m, G) ; G^m \leftarrow MPU(G, H^m) ; G \leftarrow AttentionPool(G^T, G^A, G^V) \quad (4-15)$$

相对原论文，本文改变了文本编码器、数据规模、缺失机制、任务输出与部分掩码实现，因此称为“赛题适配版”，不能把该结果描述成原论文完整复现。MulT 固定代码版本为 a670936...，EMT-DLFR 为 e421621...，完整版本和 MIT 许可保留在实验材料中。

4.4 联合预测目标与两级恢复约束

$$L_{pred} = -(1/N) \sum_i \log \hat{p}_{i, c_i} + \lambda (1/N) \sum_i Huber_1(\hat{y}_i - y_i), \quad \lambda = 1 \quad (4-16)$$

$Huber_1(e)$ 在 $|e| \leq 1$ 时为 $e^2/2$ ，否则为 $|e|-1/2$ 。分类与回归共用表示，前者关注类别边界，后者约束强度连续性。MLP、GRU、状态递推与 MulT 使用式 (4-16)。

EMT-DLFR 适配版另设完整和人工缺失两个训练视图。两者共享预测参数，完整支路只提供训练监督；低层恢复对被人工移除的原可用特征计算 SmoothL1，高层恢复在全局、文本、音频、视觉四路表示上使用 SimSiam 式对称停止梯度余弦吸引。

$$L_{rec} = \sum_m \{ [\Sigma_{i,t,j} O_{it}^m b_{it}^m \text{SmoothL1}(\hat{x}_{itj}^m - x_{itj}^m)] / \max(d^m \Sigma_{i,t} O_{it}^m b_{it}^m, 1) \} \quad (4-17)$$

$$L_{att} = -\frac{1}{2} \sum_k \text{mean}_i \{ \cos(p_{ik}^{miss}, \text{sg}(z_{ik}^{full})) + \cos(p_{ik}^{full}, \text{sg}(z_{ik}^{miss})) \} \quad (4-18)$$

$$L_{EMT} = L_{pred}^{miss} + L_{pred}^{full} + L_{rec} + L_{att} \quad (4-19)$$

式 (4-18) 在原本有可信观测的样本/模态上计算；整路自然不可用时跳过该路吸引监督。L_att 可为负，因此 EMT 训练总损失不能与只有预测项的模型直接比较。去恢复约束的消融保留两支预测监督，仅令 L_rec 和 L_att 权重为 0，避免把增加完整视图监督带来的作用混入恢复机制结论。验证和专项推理仅执行单个可见输入分支。

4.5 连续区间缺失增强

训练样本以 40% 概率保留原观测，40% 概率对单模态遮挡，20% 概率对双模态遮挡。区间比例在 10%—50% 之间采样，起点随机；双模态包含同步和错位区间。文本提前生成 8 组“遮 token 后再编码”的视图，在训练时抽取；音视频掩码在线生成。所有模型共享该接口，避免某一模型获得被遮词的完整编码。

自然不可用位置仍保留其原掩码，不人为宣称这些位置存在完整恢复目标。附件 3 虽然观测到高度同步的不可用位置及散点样式，本轮没有据此回调训练比例或阈值。当前 32 条件没有专门三模态同步遮挡，这是实验覆盖的限制，后续扩展应独立列明。

5 实验验证、模型选择与专项预测

实验依次回答四个问题：复杂融合结构是否优于简单基线，缺失模态与区间位置如何影响预测，递推与恢复机制是否带来稳定收益，以及冻结模型在专项样本上给出何种输出。各比较均保留原始数据划分、统一的输入预处理和明确的统计口径。

5.1 训练配置与模型选择规则

表 4 主要训练设置

项目	自建及普通基线	MuT 适配	EMT 及消融
文本编码	固定 BERT-Mini 256 维	同左	同左
融合规模	隐维 32	隐维 30, 5 头, 5 层	隐维 128, 4 头, 2 层
优化器	AdamW	AdamW	AdamW
学习率	0.001	0.001	0.0001
weight decay	0.0001	0.0001	0.001
batch / 最多轮次	64 / 40	64 / 40	64 / 40
早停 / 梯度裁剪	6 轮 / 5	6 轮 / 5	6 轮 / 5
主模型随机种子	17、29、43	17、29、43	17、29、43
新增调参搜索	—	本轮不搜索	本轮不搜索

每轮在完整输入与文本、音频、视觉各 30%中部缺失的四种验证条件下计算 Macro-F1，平均值最高的检查点被保留，相同时选择平均 MAE 更低者。结构按照三个种子的该指标均值排序，随后平均三个检查点的类别概率和强度输出形成集成。该顺序在正式论文方法实验前固定，不在看到集成结果后切换口径。

论文方法训练前先检查 GPU 利用率、显存、CPU 和内存负载，通过模型边界检查与小批量拟合后，在两张较空闲的 RTX4090 上分别运行。各任务结束后释放资源；耗时受共享服务器影响，不把墙钟时间当作跨设备严格算法复杂度比较。

5.2 评价指标与结果统计

5.2.1 分类与回归指标

$$Accuracy = (1/N) \sum_i 1(\hat{c}_i = c_i) ; Macro-F1 = (1/3) \sum_c F1_c \quad (5-1)$$

$$F1_c = 2TP_c / (2TP_c + FP_c + FN_c) ; Weighted-F1 = \sum_c (nc/N) F1_c \quad (5-2)$$

$$MAE = (1/N) \sum_i \vee \hat{y}_i - y_i \quad (5-3)$$

$$Pearson = \frac{\sum_i (y_i - \bar{y})(\hat{y}_i - \bar{\hat{y}})}{\sqrt{[\sum_i (y_i - \bar{y})^2 \cdot \sum_i (\hat{y}_i - \bar{\hat{y}})^2]}} \quad (5-4)$$

F1 分母为 0 时按 0 处理；Pearson 在任一变量方差为 0 时未定义，不填成虚假的有效相关系数。Macro-F1 平等对待三类，Weighted-F1 按真实类别频数加权，二者分别标明。本文不采用将中性并入正向的二分类指标。

5.2.2 随机种子与分组重采样

主候选各运行 17、29、43 三个种子，报告指标均值及样本标准差。另单独报告先平均预测再计算的集成指标；非线性的 F1 使这两种统计可能产生不同排序。历史状态模块消融只有种子 17，应与同种子的完整状态模型配对，不能拿单种子结果与三种子均值作严格归因。

对候选模型与 MLP 的预测差异，以原始 video_id 为组进行 1000 次配对 Bootstrap 重采样，当前验证包含 239 个原视频组。该区间描述本验证集内的波动，不消除模型选择偏差，也不等同于独立测试上的显著性证明。

5.3 验证集基础性能与基线对比

表 5 完整输入：三种子预测集成的验证性能

模型	Accuracy	Macro-F1	MAE	Pearson
MLP 融合	0.5824	0.5403	0.6588	0.5474
观测状态递推	0.5838	0.5305	0.6540	0.5563
MuT 适配版	0.5824	0.5375	0.6653	0.5342
EMT-DLFR 适配版	0.5783	0.5548	0.6348	0.5591
EMT 去恢复约束	0.5948	0.5628	0.6318	0.5605

表 6 四条件选模：三种子指标的均值与标准差

模型	Macro-F1 (均值±标准差)	MAE (均值±标准差)
MLP 融合	0.5392 ± 0.0092	0.6724 ± 0.0023
观测状态递推	0.5276 ± 0.0076	0.6716 ± 0.0063
MuT 适配版	0.5307 ± 0.0071	0.6916 ± 0.0144
EMT-DLFR 适配版	0.5412 ± 0.0151	0.6584 ± 0.0197
EMT 去恢复约束	0.5382 ± 0.0041	0.6586 ± 0.0262

按表 6 所对应的预定规则，本轮四个主候选中选 EMT-DLFR。其完整输入集成 Macro-F1 较 MLP 提高 0.0145，MAE 降低 0.0240，但 Accuracy 从 0.5824 降至 0.5783。四条件集成 Macro-F1 为 0.5483、MAE 为 0.6414，原 MLP 分别为 0.5409 和 0.6644。该结果体现了类别均衡识别和总体准确率之间的取舍。

MuT 在本设置下未超过 MLP，说明更复杂的两两跨模态注意力不必然带来收益。自建状态递推也没有稳定超过简单融合，不能将其写成最终性能最优方法。另需保留一个负面机制结果：去恢复约束的 EMT 集成在完整输入上取得 0.5628 Macro-F1 和 0.6318 MAE，优于完整 EMT-DLFR；其三种子指标均值排序却不同，本文不据此事后修改选模口径。

EMT-DLFR 相对 MLP，完整输入 Macro-F1 差的 95% 分组 Bootstrap 区间为 $[-0.0165, 0.0442]$ ，跨过 0；MAE 差的区间为 $[-0.0466, -0.0014]$ 。后者在当前开发验证中支持较低回归误差，但由于验证参与选模，仍不应推广为未经独立评估的泛化保证。

完整输入：五种方法三种子集成




图4 完整输入下的五种方法集成性能

选模依据：三次独立训练的均值与标准差




图5 四条件选模指标的三种子均值与标准差

5.4 模态缺失对预测性能的影响规律

5.4.1 不同缺失模态类型的影响

表 7 EMT-DLFR 集成：不同缺失模态与比例（前中后位置平均）

模态	目标遮挡比例	Macro-F1	MAE
文本	10%	0.5482	0.6418
文本	30%	0.5330	0.6602
文本	50%	0.5140	0.6803
音频	10%	0.5577	0.6340
音频	30%	0.5587	0.6335
音频	50%	0.5584	0.6332
视觉	10%	0.5517	0.6329
视觉	30%	0.5480	0.6342
视觉	50%	0.5414	0.6355

文本缺失对预测影响最明显：目标比例从 10%增至 50%时，平均 Macro-F1 由 0.5482 降至 0.5140，MAE 由 0.6418 升至 0.6803。视觉缺失的 Macro-F1 也随比例增加而下降，但变化幅度较小。音频遮挡后本轮指标没有出现单调恶化，甚至略好于完整输入；这不能解释为音频无效或遮挡必然有益，可能涉及冗余信息、噪声和有限样本波动。

5.4.2 不同缺失位置的影响

表 8 EMT-DLFR 集成：30%遮挡下的位置效应

模态	位置	Macro-F1	MAE
文本	前部	0.5335	0.6642
文本	中部	0.5372	0.6606
文本	后部	0.5283	0.6558
音频	前部	0.5518	0.6351
音频	中部	0.5532	0.6349
音频	后部	0.5711	0.6304
视觉	前部	0.5495	0.6350
视觉	中部	0.5480	0.6353
视觉	后部	0.5466	0.6323

文本后部 30%遮挡的 Macro-F1 为 0.5283，低于前部 0.5335 和中部 0.5372，但其 MAE 并非最大。视觉三种位置差异也较小。由此不能给出“中部一定最重要”或“后部一定最危险”的普遍规

律；应分别报告分类、回归和样本层面的变化。当前位置实验以存储内容序列定位，不代表等长秒级区间。

5.4.3 不同缺失时长与缺失率的影响

比例实验在 10%、30%、50%三个水平进行，区间宽度由式（4-2）计算。由于样本长度不同，相同比例对应不同的绝对位置数；原始不可用位置也会使实际移除观测数不同。结果材料另存每样本的目标预算、实际删除数及原可用数，避免将同一比例视为相同信息损失。




图 6 连续缺失比例与分类表现：三种种子均值及标准差




图 7 连续缺失比例与回归误差：三种种子均值及标准差

表 9 EMT-DLFR 集成：补充复杂缺失条件

条件	Macro-F1	MAE
audio_vision_30_sync	0.5494	0.6356
text_audio_30_sync	0.5336	0.6604
audio_vision_30_offset	0.5441	0.6324
audio_30_two_blocks	0.5651	0.6307

补充条件包括音视频同步、文本音频同步、音视频错位及音频双块遮挡。双块与单块的内容位置总预算保持一致，用以区分遮挡总量和分布形态。当前条件覆盖仍有限，不外推为对所有三模态联合缺失模式均已验证鲁棒。

5.5 核心模块消融实验

表 10 状态模型消融：固定种子 17、同一四条件指标

变体	Macro-F1	MAE
完整状态模型	0.5352	0.6651
去缺失增强	0.5286	0.6717
去间隔提示	0.5329	0.6654
去历史递推	0.5373	0.6769

5.5.1 连续缺失增强的作用

固定种子 17 时，状态模型加入缺失增强后四条件 Macro-F1 从 0.5286 升至 0.5352，MAE 从 0.6717 降至 0.6651，提供了该候选上的正向初步证据。但三种子 GRU 对照中，增强版 Macro-F1 均值 0.5285 略低于无增强版 0.5306，MAE 则由 0.6762 降至 0.6651。因此，增强收益依赖模型与指标，不能写成所有模型全面提升。

5.5.2 缺失状态信息的作用

去间隔提示变体仍保留可用性掩码，只移除 log 间隔特征。种子 17 下其 Macro-F1 为 0.5329，完整状态模型为 0.5352，差值较小；MAE 分别为 0.6654 与 0.6651。故该消融只检验连续间隔提示的附加作用，不能宣称已证明全部观测掩码的价值，也不能凭一个种子断言稳定提升。

5.5.3 时序状态递推的作用

去历史递推后 Macro-F1 为 0.5373，略高于完整状态模型 0.5352，但 MAE 升至 0.6769。该结果提示历史状态对连续强度估计可能更有帮助，而分类提升并不成立。不同预测目标的最优结构可能不同，本文据此保留状态递推作为有解释的候选方案，而不将机制直觉当作实验证明。

5.5.4 论文模型两级恢复约束的补充消融

EMT-DLFR 与去恢复变体均完成三个种子，后者仍保留完整/缺失视图两支预测监督。四条件单次训练 Macro-F1 均值分别为 0.5412 和 0.5382，MAE 分别为 0.6584 和 0.6586；但先集成预测后的四条件 Macro-F1 分别为 0.5483 和 0.5529。恢复机制在不同统计口径下没有稳定占优，因此本轮不能把相对 MLP 的全部收益归因于低层重建和高层吸引。

两级恢复约束是否有效：两变体保留相同双支监督




图 8 两级恢复约束消融：保持相同的完整/缺失视图监督

5.6 预测结果可视化与错误归因

表 11 EMT-DLFR 完整输入混淆矩阵（行真实，列预测）

真实类别	预测负向	预测中性	预测正向	召回率
负向	115	42	49	55.83%
中性	34	80	70	43.48%
正向	51	61	226	66.86%

EMT-DLFR 的中性召回率为 43.48%，高于 MLP 的 29.89%，这有助于解释 Macro-F1 提高而 Accuracy 略降的现象。弱情感、中性附近边界和长文本上下文仍容易出现错误。类别头与强度头共享表示但没有强制符号一致性，相关冲突应作为诊断结果单独统计。

完整输入：逐类识别结果




图 9 MLP、MulT 与 EMT-DLFR 的逐类识别表现

完整输入：情感强度预测




图 10 三种方法预测强度与真实强度的对应关系

对验证错误清单进行文本层面的初步检查，可区分“能由现有证据确认的输入限制”与“需要原音视频进一步核验的解释假说”。例如，样本 102858\$\$_4 的原转写很长，预测将强正向判为负向，可能涉及固定词元预算未覆盖后部评价；最终应核对实际 token 保留范围。样本 f_ZJ7L14oYQ\$\$_27 包含 “I don’t have to worry about it anymore”，否定作用于担忧而表达正向含义，不能仅因出现否定词就判负向。

另一个样本 TWszOxkOV0w\$\$_1 含 “outrage”并讨论 CEO 报酬与绩效，被预测为正向，体现了复杂议题中的情感对象和立场识别困难。这些是结合真实文本提出的错误分析线索，尚未通过归因干预证明模型具体使用了哪些词；没有原视频核验时，不编造“表情与声音冲突”等原因。

EMT-DLFR适配版相对MLP：按原视频分组的Bootstrap 95%区间




图 11 EMT-DLFR 相对 MLP 的配对差值及 95%分组 Bootstrap 区间

5.7 附件 3 全量预测结果汇总与结果文件说明

按既定规则冻结 EMT-DLFR 三个检查点后，对附件 3 对齐版全部 30 条样本推理。类别概率与强度分别在三个种子间取均值，类别由平均概率最大项确定。输入继续使用官方附件专用 UNK 策略、训练统计量和同一文本编码器，没有跨版本补全、标签查表或专项阈值调整。

表 12 附件 3 全部 30 条预测（无真实标签）

原文件编号	极性	强度	P(负向)	P(中性)	P(正向)
附件 3_01	中性	-0.4036	0.4230	0.4553	0.1217
附件 3_02	中性	-0.0026	0.1811	0.6224	0.1965
附件 3_03	中性	-0.0854	0.2877	0.4159	0.2964
附件 3_04	正向	0.3607	0.0967	0.2856	0.6177
附件 3_05	负向	-1.5315	0.9119	0.0538	0.0343
附件 3_06	正向	0.7625	0.0181	0.1688	0.8131
附件 3_07	中性	-0.0506	0.2175	0.6035	0.1790
附件 3_08	负向	-0.0655	0.4614	0.0895	0.4491
附件 3_09	正向	0.8491	0.0378	0.1069	0.8553
附件 3_10	中性	-0.1877	0.1628	0.7271	0.1101
附件 3_11	正向	0.4063	0.0219	0.3216	0.6565
附件 3_12	正向	0.2791	0.1664	0.2819	0.5517
附件 3_13	正向	0.0908	0.3764	0.1976	0.4261
附件 3_14	负向	-0.1013	0.4399	0.2562	0.3039
附件 3_15	正向	0.5153	0.0290	0.2385	0.7325
附件 3_16	正向	1.6099	0.0122	0.0233	0.9645
附件 3_17	中性	-0.1591	0.3803	0.4246	0.1952
附件 3_18	正向	-0.0236	0.3367	0.2793	0.3841
附件 3_19	中性	0.0180	0.2784	0.4163	0.3053
附件 3_20	正向	0.3558	0.1227	0.3393	0.5380
附件 3_21	正向	0.3855	0.0583	0.2463	0.6955
附件 3_22	负向	-0.1411	0.4888	0.1895	0.3217
附件 3_23	正向	0.5584	0.0296	0.2044	0.7660
附件 3_24	负向	-0.9661	0.8006	0.0795	0.1199
附件 3_25	中性	0.0142	0.2312	0.4903	0.2785
附件 3_26	正向	0.3695	0.1339	0.2597	0.6064
附件 3_27	正向	0.9323	0.0393	0.1007	0.8600
附件 3_28	中性	0.2968	0.0314	0.5168	0.4518
附件 3_29	正向	0.8512	0.0318	0.0737	0.8946
附件 3_30	正向	0.3546	0.1503	0.2388	0.6110

预测类别分布为负向 5 条、中性 9 条、正向 16 条。这是模型输出分布，不是专项准确率；附件 3 没有标签，不能以预测变化或正向比例接近训练集为依据宣称效果提高。完整 CSV 保留原文件编

号、英文类别、强度和三类概率。溯源 JSON 记录输入哈希、检查点哈希、预处理版本、不可用区间和质量标记。

本轮新模型 5 项针对性测试、GPU 小批量拟合及检查点重载验证均通过；此前 10 项输入不变量检查和原始数据/缓存逐项核对亦通过。将选定模型复现包解压到独立目录后，30 条 CSV 和溯源文件与开发目录输出逐字节一致。新复现包约 36.09MB，仅覆盖第二问，整题仍需为第一问特征及第三问解释材料控制总附件体积。

当前结果支持将 EMT 结构作为进一步研究的候选，但不支持把恢复约束或状态递推宣称为稳定最优机制。下一步若调整编码器、扩大训练预算或新增三模态同步压力测试，应作为新的实验版本记录，继续保留当前开发验证与专项推理之间的隔离。

5.8 适用范围与后续任务衔接

现有结果主要支持两点：输入掩码的正确处理是所有比较成立的前提；在本轮开发验证中，EMT-DLFR 适配版的回归误差优于 MLP，而分类改善与恢复机制收益仍存在不确定性。因此，对模型优势应限定到对应任务、缺失条件与统计口径，不能将单项指标提升扩展为全面最优。

第一问后续需从附件 1 原视频自主提取特征并建立真实时间映射。已完成的 100 条原媒体核查只能作为处理清单，不能代替特征成果。第三问可复用第二问的预测接口和输入扰动工具，但模态贡献、局部证据及其忠实性需要单独验证，且必须回查附件 4 原素材。二者所需的证据不能由现有验证分数或重建表示替代。

参考文献

[1] 2026 年中国研究生数学建模竞赛 E 题. 复杂场景下多模态情感预测的数学建模与算法设计：题面及附件 1—4[Z]. 2026.

[2] LIU Z, SHEN Y, LAKSHMINARASIMHAN V B, et al. Efficient Low-rank Multimodal Fusion With Modality-Specific Factors[C]//Proceedings of ACL. 2018. <https://aclanthology.org/P18-1209/>.

[3] TSAI Y H H, BAI S, LIANG P P, et al. Multimodal Transformer for Unaligned Multimodal Language Sequences[C]//Proceedings of ACL. 2019. <https://arxiv.org/abs/1906.00295>. 官方代码：<https://github.com/yaohungt/Multimodal-Transformer>.

[4] YUAN Z, LI W, XU H, et al. Transformer-based Feature Reconstruction Network for Robust Multimodal Sentiment Analysis[C]//Proceedings of ACM Multimedia. 2021. 官方代码：<https://github.com/thuiar/TFR-Net>.

[5] SUN L, LIAN Z, LIU B, TAO J. Efficient Multimodal Transformer with Dual-Level Feature Restoration for Robust Multimodal Sentiment Analysis[J]. IEEE Transactions on Affective Computing,

2023（在线发表年份按官方代码引用）. <https://arxiv.org/abs/2208.07589>. 官方代码: <https://github.com/sunlicai/EMT-DLFR>.

[6] DEVLIN J, CHANG M W, LEE K, TOUTANOVA K. BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding[C]//Proceedings of NAACL-HLT. 2019. <https://aclanthology.org/N19-1423/>.